

项目描述： 企业级 Agentic RAG 知识问答系统。核心创新点在于用 LLM Agent 替代传统硬编码检索流水线——模型在运行时自主分析问题意图，动态编排向量检索、关键词检索、联网搜索、长期记忆等工具组合，不同问题走不同检索链路。最终答案经 LLM 自检纠错，每条回答均可追溯至原始文档的章节与页码。系统同时通过 MCP 协议对外开放全部检索能力，支持任意 AI Agent 直接调用企业知识库。

核心技术： Spring Boot + Spring AI + Milvus + Lucene + Redis + MySQL + MyBatis-Plus + MinIO + Vue 3 + TypeScript

核心职责与贡献

- Agentic RAG 核心引擎：** 基于 Spring AI Function Calling 实现 ReAct Agent 决策循环，LLM 根据问题特征实时决定调用哪些工具、调用几次、是否追加检索，彻底替代传统 if-else 路由；设计 QueryRouter 规则路由作为降级路径，Function Calling 异常时无缝切换，保证检索链路零中断。
- 七步检索精炼链路（核心亮点）：**
 - Query Rewrite：** LLM 将口语化提问改写为检索优化表达，短查询（≤10 字）自动跳过，改写失败回退原始查询；
 - 混合召回：** Milvus 1024 维 COSINE 语义检索处理模糊概念类问题，Lucene SmartCN + BM25 处理精确术语 / 条款，Tavily 联网检索补充时效性内容，三路并行互补；
 - RRF 倒数秩融合：** $score(d) = \sum 1/(k + rank_i(d))$ ，将异构评分体系统一为排序信号，跨路命中标记 HYBRID 提权，消除单路召回盲区；
 - Cross-Encoder 精排：** gte-rerank 对 query-chunk 对逐一计算细粒度相关性，取 Top-6 进入生成阶段；模型不可用时降级为 60% 原始分 + 40% 关键词命中率 混合评分；
 - 上下文压缩：** 前缀去重（50 字）+ 单片截断（800 字）+ 总量控制，在保留高相关内容的同时严格控制 Token 开销；
 - Self-Reflection 自检：** 生成完成后 LLM 从事实一致性、完整性、来源匹配三个维度评分，置信度 < 0.7 自动触发重新检索，最多 2 轮纠错循环，杜绝幻觉输出。
- MCP 工具复用架构：** 设计 @Tool 单实例双轨接入——内部 Agent 通过 Function Calling 调用，外部客户端通过 MCP 协议调用，共享同一组 Bean，零重复代码。设计 AgentToolContext (ThreadLocal) 实现工具执行结果的线程级自动收集，工具层无需感知调用来源与上下文参数。
- 跨会话长期记忆：** Agent 对话时自动识别用户显式偏好并写入 Redis，后续会话通过 recall_memory 工具主动召回，结合用户画像注入 Prompt，实现追问感知与个性化回答。
- 全链路容错与热配置：** 每层独立降级方案（嵌入失败 → 随机向量兜底、重排不可用 → 关键词频率降级、安全审查失败 → 规则兜底）；所有 RAG 参数与 LLM 模型均支持数据库级热切换，运行时生效，无需重启。